

Organizace cvičení, úvod do statistiky a deskriptivní statistika

—
Supplementum ke cvičení 4ST210 Statistika pro finance

Lubomír Štěpánek^{1, 2}



¹Oddělení biomedicínské statistiky
Ústav biofyziky a informatiky
1. lékařská fakulta
Univerzita Karlova, Praha



²Katedra biomedicínské informatiky
Fakulta biomedicínského inženýrství
České vysoké učení technické v Praze

(2020) Lubomír Štěpánek, CC BY-NC-ND 3.0 (CZ)



Dílo lze dále svobodně šířit, ovšem s uvedením původního autora a s uvedením původní licence. Dílo není možné šířit komerčně ani s ním jakkoliv jinak nakládat pro účely komerčního zisku. Dílo nesmí být jakkoliv upravováno. Autor neručí za správnost informací uvedených kdekoli v předložené práci, přesto vynaložil nezanedbatelné úsilí, aby byla uvedená fakta správná a aktuální, a práci sepsal podle svého nejlepšího vědomí a svých „nejlepších“ znalostí problematiky.

- 1 Organizace předmětu
- 2 Středoškolské opakování
- 3 Základní pojmy
- 4 Deskriptivní statistika
- 5 Literatura

Online složka předmětu

- prezentace a další materiály ke cvičení jsou dostupné na

https://github.com/LStepanek/4ST210_Statistika_pro_finance

Organizace předmětu

- cvičící
 - Ing. MUDr. Lubomír Štěpánek
- email

lubomir.stepanek@vse.cz

- konzultační hodiny
 - v NB366 vždy v úterý mezi 11:00–12:00, po předchozí emailové domluvě i jindy

Podklady a materiály

- oficiální vzorcovník, oficiální statistické tabulky a výčet důležitých kapitol z doporučené literatury je zde

<https://kstp.vse.cz/predmety-4st201-4st210-a-4st204/>

- tabulky i vzorcovník je vhodné nosit s sebou vytisklý na cvičení
- prezentace ze cvičení a vzorové příklady budou v online složce předmětu, tedy

<https://github.com/LStepanek/4ST210> Statistika pro finance

Doporučená literatura



Hindls, Richard, Markéta Arltová, Stanislava Hronová, Ivana Malá, Luboš Marek, Iva Pecáková a Řezanková Hana. *Statistika v ekonomii*. Praha: Professional Publishing, 2018. ISBN: 978-80-88260-09-7.



Marek, Luboš. *Statistika v příkladech*. Praha: Professional Publishing, 2015. ISBN: 978-80-7431-153-6.

Cíle předmětu

- smyslem je uvést studenty do deskriptivní statistiky, dále do teorie pravděpodobnosti a nakonec do induktivní statistiky

Náplň předmětu

- bude procvičena látka na úrovni učebnice *Statistika v ekonomii*¹
- probírané okruhy
 - úvod do statistiky
 - deskriptivní statistika
 - pravděpodobnost
 - indukativní statistika
 - testování hypotéz
 - korelační a regresní analýza
 - časové řady
 - indexní analýza

¹Richard Hindls, Markéta Arltová, Stanislava Hronová, Ivana Malá, Luboš Marek, Iva Pecáková a Řezanková Hana. *Statistika v ekonomii*. Praha: Professional Publishing, 2018. ISBN: 978-80-88260-09-7

Hodnocení předmětu

- v průběhu semestru lze získat až $2 \times 20 = 40$ bodů za průběžné testy
- bodové rozložení je následující

typ testování	maximální možný bodový zisk
první průběžný test	20
druhý průběžný test	20
závěrečný test	60
Σ	100

Průběžné testy

- za každý z průběžných testů je možné získat maximálně 20 bodů, celkem tedy maximálně 40 bodů
- každý z průběžných testů se obvykle skládá právě ze tří početních příkladů
- na každý průběžný test je oficiálně 45 minut (na mých cvičeních však 45–50 minut)
- u průběžných testů je povoleno používat
 - neprogramovatelný kalkulátor,
 - MS Excel®
 - oficiální vzorcovník (bez vlastních poznámek)
 - oficiální statistické tabulky
- pro připuštění k závěrečnému testu je nutné získat v součtu za oba průběžné testy **alespoň 16 bodů**

Průběžné testy

- první průběžný test budeme psát pravděpodobně 6. vyučovací týden, tj. 24. března 2020
- druhý průběžný test budeme psát pravděpodobně 11. vyučovací týden, tj. 28. dubna 2020

- $$\sum_{i=1}^n x_i = x_1 + x_2 + \cdots + x_n$$

$$= \text{SUMA}(x_1 : x_n)$$

Použitá matematická notace

- součin $n \in \mathbb{N}$ čísel x_1, x_2, \dots, x_n značíme též symbolem (velké) pí,
 $\prod_{i=1}^n x_i$, tedy

$$\prod_{i=1}^n x_i = x_1 \cdot x_2 \cdot \dots \cdot x_n$$

► MS Excel®

=SOUČIN($x_1 : x_n$)

Použitá matematická notace

- součin všech přirozených čísel $1, 2, \dots, n - 1, n$ obvykle značíme $n!$ a čteme „en faktoriál“, tedy

$$n! = n \cdot (n - 1) \cdot \dots \cdot 2 \cdot 1$$

► MS Excel®

=FAKTORIÁL(n)

Použitá matematická notace

- počet všech možností, kolika lze z $n \in \mathbb{N} \cup \{0\}$ prvků vybrat $k \in \mathbb{N} \cup \{0\}$ prvků tak, že $k \leq n$ a nezáleží na pořadí výběru, obvykle značíme $\binom{n}{k}$, a platí

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$

► MS Excel®

=KOMBINACE($n; k$)

Příklad

(i) Najděme $x \in \mathbb{N}$ takové, aby

$$\binom{x}{2} = 10.$$

(ii) Najděme $x \in \mathbb{N}$ takové, aby

$$\binom{x}{3} = 455.$$

(iii) Najděme $x \in \mathbb{N}$ takové, aby

$$x! = 362880.$$

Příklad

- Jirka má právě sedm různých triček, čtyři kalhoty a pět párů bot.
 - (i) Kolika navzájem různými způsoby může vytvořit svůj outfit?
 - (ii) Kolik by potřeboval triček, aby měl každý den v roce originální² outfit?


²Ve smyslu jiný outfit než během kteréhokoliv ostatního dne v roce.

1998, 1999, 2000, 2001, 2002, 2003, 2004, 2005, 2006, 2007, 2008, 2009, 2010, 2011, 2012, 2013, 2014, 2015, 2016, 2017, 2018, 2019, 2020, 2021, 2022, 2023, 2024, 2025, 2026, 2027, 2028, 2029, 2030, 2031, 2032, 2033, 2034, 2035, 2036, 2037, 2038, 2039, 2040, 2041, 2042, 2043, 2044, 2045, 2046, 2047, 2048, 2049, 2050, 2051, 2052, 2053, 2054, 2055, 2056, 2057, 2058, 2059, 2060, 2061, 2062, 2063, 2064, 2065, 2066, 2067, 2068, 2069, 2070, 2071, 2072, 2073, 2074, 2075, 2076, 2077, 2078, 2079, 2080, 2081, 2082, 2083, 2084, 2085, 2086, 2087, 2088, 2089, 2090, 2091, 2092, 2093, 2094, 2095, 2096, 2097, 2098, 2099, 2100, 2101, 2102, 2103, 2104, 2105, 2106, 2107, 2108, 2109, 2110, 2111, 2112, 2113, 2114, 2115, 2116, 2117, 2118, 2119, 2120, 2121, 2122, 2123, 2124, 2125, 2126, 2127, 2128, 2129, 2130, 2131, 2132, 2133, 2134, 2135, 2136, 2137, 2138, 2139, 2140, 2141, 2142, 2143, 2144, 2145, 2146, 2147, 2148, 2149, 2150, 2151, 2152, 2153, 2154, 2155, 2156, 2157, 2158, 2159, 2160, 2161, 2162, 2163, 2164, 2165, 2166, 2167, 2168, 2169, 2170, 2171, 2172, 2173, 2174, 2175, 2176, 2177, 2178, 2179, 2180, 2181, 2182, 2183, 2184, 2185, 2186, 2187, 2188, 2189, 2190, 2191, 2192, 2193, 2194, 2195, 2196, 2197, 2198, 2199, 2200, 2201, 2202, 2203, 2204, 2205, 2206, 2207, 2208, 2209, 2210, 2211, 2212, 2213, 2214, 2215, 2216, 2217, 2218, 2219, 2220, 2221, 2222, 2223, 2224, 2225, 2226, 2227, 2228, 2229, 2230, 2231, 2232, 2233, 2234, 2235, 2236, 2237, 2238, 2239, 2240, 2241, 2242, 2243, 2244, 2245, 2246, 2247, 2248, 2249, 2250, 2251, 2252, 2253, 2254, 2255, 2256, 2257, 2258, 2259, 2260, 2261, 2262, 2263, 2264, 2265, 2266, 2267, 2268, 2269, 2270, 2271, 2272, 2273, 2274, 2275, 2276, 2277, 2278, 2279, 2280, 2281, 2282, 2283, 2284, 2285, 2286, 2287, 2288, 2289, 2290, 2291, 2292, 2293, 2294, 2295, 2296, 2297, 2298, 2299, 2300, 2301, 2302, 2303, 2304, 2305, 2306, 2307, 2308, 2309, 2310, 2311, 2312, 2313, 2314, 2315, 2316, 2317, 2318, 2319, 2320, 2321, 2322, 2323, 2324, 2325, 2326, 2327, 2328, 2329, 2330, 2331, 2332, 2333, 2334, 2335, 2336, 2337, 2338, 2339, 2340, 2341, 2342, 2343, 2344, 2345, 2346, 2347, 2348, 2349, 2350, 2351, 2352, 2353, 2354, 2355, 2356, 2357, 2358, 2359, 2360, 2361, 2362, 2363, 2364, 2365, 2366, 2367, 2368, 2369, 2370, 2371, 2372, 2373, 2374, 2375, 2376, 2377, 2378, 2379, 2380, 2381, 2382, 2383, 2384, 2385, 2386, 2387, 2388, 2389, 2390, 2391, 2392, 2393, 2394, 2395, 2396, 2397, 2398, 2399, 2400, 2401, 2402, 2403, 2404, 2405, 2406, 2407, 2408, 2409, 2410, 2411, 2412, 2413, 2414, 2415, 2416, 2417, 2418, 2419, 2420, 2421, 2422, 2423, 2424, 2425, 2426, 2427, 2428, 2429, 2430, 2431, 2432, 2433, 2434, 2435, 2436, 2437, 2438, 2439, 2440, 2441, 2442, 2443, 2444, 2445, 2446, 2447, 2448, 2449, 2450, 2451, 2452, 2453, 2454, 2455, 2456, 2457, 2458, 2459, 2460, 2461, 2462, 2463, 2464, 2465, 2466, 2467, 2468, 2469, 2470, 2471, 2472, 2473, 2474, 2475, 2476, 2477, 2478, 2479, 2480, 2481, 2482, 2483, 2484, 2485, 2486, 2487, 2488, 2489, 2490, 2491, 2492, 2493, 2494, 2495, 2496, 2497, 2498, 2499, 2500, 2501, 2502, 2503, 2504, 2505, 2506, 2507, 2508, 2509, 2510, 2511, 2512, 2513, 2514, 2515, 2516, 2517, 2518, 2519, 2520, 2521, 2522, 2523, 2524, 2525, 2526, 2527, 2528, 2529, 2530, 2531, 2532, 2533, 2534, 2535, 2536, 2537, 2538, 2539, 2540, 2541, 2542, 2543, 2544, 2545, 2546, 2547, 2548, 2549, 2550, 2551, 2552, 2553, 2554, 2555, 2556, 2557, 2558, 2559, 2560, 2561, 2562, 2563, 2564, 2565, 2566, 2567, 2568, 2569, 2570, 2571, 2572, 2573, 2574, 2575, 2576, 2577, 2578, 2579, 2580, 2581, 2582, 2583, 2584, 2585, 2586, 2587, 2588, 2589, 2590, 2591, 2592, 2593, 2594, 2595, 2596, 2597, 2598, 2599, 2600, 2601, 2602, 2603, 2604, 2605, 2606, 2607, 2608, 2609, 2610, 2611, 2612, 2613, 2614, 2615, 2616, 2617, 2618, 2619, 2620, 2621, 2622, 2623, 2624, 2625, 2626, 2627, 2628, 2629, 2630, 2631, 2632, 2633, 2634, 2635, 2636, 2637, 2638, 2639, 2640, 2641, 2642, 2643, 2644, 2645, 2646, 2647, 2648, 2649, 2650, 2651, 2652, 2653, 2654, 2655, 2656, 2657, 2658, 2659, 2660, 2661, 2662, 2663, 2664, 2665, 2666, 2667, 2668, 2669, 2670, 2671, 2672, 2673, 2674, 2675, 2676, 2677, 2678, 2679, 26

Dělení statistiky

- deskriptivní statistika
 - popisuje data, ale nedělá na nich žádné „velké“ závěry
- induktivní statistika
 - pozoruje konkrétní data a vyvozuje z nich obecné závěry, ovšem s udáním stupně jejich spolehlivosti

Vzájemný vztah deskriptivní a induktivní statistiky



Pojem *statistický znak, veličina*

- statistický znak, veličina
 - měřitelná (veličina) či jinak zjistitelná (znak) charakteristika našeho zájmu
 - např. tělesná výška, pohlaví, mzda, apod.

Pojem *statistická jednotka*

- statistická jednotka
 - základní atomický prvek zájmu, u něž lze měřit nebo jinak získat hodnotu statistického znaku či veličiny
 - např. student, pacient, stát, molekula, apod.

Pojem *statistický soubor*

- statistický soubor
 - množina statistických jednotek (prvků statistického souboru)
 - např. třída žáků, kohorta pacientů, apod.

Vztah statistického znaku (veličiny), jednotky a souboru

- každá statistická jednota (prvek) statistického souboru má svou hodnotu³ určitého zkoumaného statistického znaku či veličiny (jde-li o měřitelný znak)
- např. *ve školní třídě změříme tělesnou výšku každého žáka*
 - *školní třída* je statistický soubor
 - *žáci* jsou statistické jednotky (prvky)
 - *tělesná výška* je statistická veličina

³ta může eventuálně chybět nebo být neznámá (missing value)

Intermezzo

- měříme tělesné hmotnosti v kohortě pacientů-diabetiků na interním oddělení
- určíme, co je v takovém případě
 - statistickým znakem, resp. veličinou
 - statistickou jednotkou
 - statistickým souborem

Cíle deskriptivní statistiky

- cílem je popsat soubor dat
 - číselně (resp. tabulkou)
 - graficky
- popisné číselné ukazatele i grafické přístupy se liší, pokud jde
 - o kvantitativní statistický znak (veličinu)
 - o kvalitativní statistický znak

Kvalitativní znak

- je vyjádřen obvykle slovně
- pokud vyjádřen číslem, pak nese pouze „katalogizační“ význam a není smysluplné s ním provádět aritmetické operace
- někdy též označován jako *kategorický* typ dat
- např.
 - pohlaví {muž, žena}, rodinný stav muže {svobodný, ženatý, rozvedený, vdovec, registrovaný} atd.
 - pořadí v závodu, grade tumoru {1, 2, 3, 4} atd.

Příklad

- určíme typ znaku u následujících příkladů
 - procentuální úspěšnost v testu v souboru studentů jednoho kruhu [%]
 - soubor všech červencových dní jednoho roku (1., 2., ..., 31.)
 - směnný kurz USD–CZK k danému datu
 - soubor čísel všech tramvají projíždějících zastávkou Husinecká
 - počet porodů v jedné porodnici za jednu noc
 - staging kolorektálního karcinomu {1, 2, 3, 4}

Popis kvantitativního znaku

- např. tělesná výška, glykémie, výše mzdy, sázkový kurz atd.
- číselně (**center – spread – shape!**)
 - mírou polohy (*center*)
 - aritmetický průměr, geometrický průměr, harmonický průměr, medián, modus, kvantil
 - mírou variability (*spread*)
 - rozpětí (min-max), směrodatná odchylka, rozptyl, kvantil
 - tvar (*shape*)⁴
 - šikmost, špičatost
- graficky
 - krabicový diagram (boxplot)
 - histogram

⁴lépe jen graficky

Aritmetický průměr

- pro n čísel x_1, x_2, \dots, x_n spočítáme jejich aritmetický průměr jako

$$\bar{x} = \frac{x_1 + x_2 + \cdots + x_n}{n} = \frac{1}{n} \sum_{i=1}^n x_i$$

► MS Excel®


$$= \text{PRŮMĚR}(x_1 : x_n)$$

- pro n hodnot x_1, x_2, \dots, x_n tvořících soubor m čísel takových, že je mezi nimi číslo x_1 právě m_1 -krát, číslo x_2 právě m_2 -krát, \dots , číslo x_n právě m_n -krát a je $m_1 + m_2 + \dots + m_n = m$, spočítáme jejich aritmetický průměr jako

$$\bar{x} = \frac{m_1x_1 + m_2x_2 + \cdots + m_nx_n}{m} = \frac{1}{m} \sum_{i=1}^n m_i x_i$$


Příklad

- určeme aritmetický průměr z následujícího souboru tělesných výšek




Příklad

- určíme aritmetický průměr z následujícího souboru tělesných výšek
- $$\bar{x} = \frac{165+176+152+194+171}{5} \doteq 171,6 \text{ [cm]}$$




Příklad

- určíme aritmetický průměr z následujícího souboru tělesných výšek
- $\bar{x} = \frac{165+176+152+194+171}{5} \doteq 171,6 \text{ [cm]}$
- kolik navzájem různých průměrů může mít jeden soubor čísel?



Příklad

- určíme aritmetický průměr z následujícího souboru tělesných výšek
- $\bar{x} = \frac{165+176+152+194+171}{5} \doteq 171,6 \text{ [cm]}$
- kolik navzájem různých průměrů může mít jeden soubor čísel?
- pouze jeden



Geometrická interpretace aritmetického průměru

- pokud zavěsíme n jednogramových závaží na pozice čísel x_1, x_2, \dots, x_n pravítka, hodnota průměru \bar{x} je v těžišti soustavy

Geometrická interpretace aritmetického průměru

- pokud zavěšíme n jednogramových závaží na pozice čísel x_1, x_2, \dots, x_n pravítka, hodnota průměru \bar{x} je v těžišti soustavy
- *Důkaz.* Označme polohu těžiště na pravítku x_t , dále hmotnost závaží je $m = 1$ [g] a gravitační konstanta je $g \doteq 10$ [m/s²]. Zřejmě, pokud jde o těžiště, pak je soustava v rovnovážném klidu a musí platit zákon zachování hybnost. Hybnost je u soustavy v rovnovážném klidu nulová, tedy

$$(x_1 - x_t)mg + (x_2 - x_t)mg + \dots + (x_n - x_t)mg = 0$$

$$(x_1 - x_t) + (x_2 - x_t) + \dots + (x_n - x_t) = 0$$

$$x_1 + x_2 + \dots + x_n - nx_t = 0$$

$$x_1 + x_2 + \dots + x_n = nx_t$$

$$\frac{x_1 + x_2 + \dots + x_n}{n} = x_t.$$

Příklad

- V souboru šestnácti čísel je jejich aritmetických průměr roven 10,3. Jak se změní jejich aritmetický průměr, pokud
 - zvýšíme každé z čísel o 5,2?
 - zvýšíme každé z čísel třikrát?
 - zvýšíme polovinu čísel o 7,2 a zbytek čísel zmenšíme o 7,2?
 - zvýšíme polovinu čísel o 3,1 a druhou polovinu čísel zmenšíme o 1,1?

Příklad

- Ve třídě 8. A jedné základní školy bylo původně 32 žáků. Určitý počet žáků, jejichž průměrný inteligenční kvocient je 120, byl z kázeňských důvodů přesunut ze třídy 8. A do jiné třídy dané školy. Díky tomu vzrostl průměrný inteligenční kvocient zbylých žáků v 8. A ze 127 na 128. Určete, kolik žáků bylo přesunuto ze třídy 8. A do jiné zmíněné třídy.

Geometrický průměr

- pro n nezáporných čísel x_1, x_2, \dots, x_n spočítáme jejich geometrický průměr jako

$$\bar{x}_G = \sqrt[n]{x_1 \cdot x_2 \cdot \dots \cdot x_n} = \sqrt[n]{\prod_{i=1}^n x_i}$$

► MS Excel®

=GEOMEAN($x_1 : x_n$)

Příklad

- Během čtyř let cena akcie meziročně postupně vzrostla o 8 %, pak o 12 %, poté o 3 % a nakonec klesla o 1 %. Pokud by se během těchto čtyřech let měnila cena akcie meziročně vždy o konstantní procento, o kolik by to bylo?

Příklad

- Ukažme, že pokud se geometrický průměr původního množství n kladných čísel rovnal \bar{x}_G , pak aritmetický průměr logaritmů původních čísel je roven $\log \bar{x}_G$.

Harmonický průměr

- pro n nenulových čísel x_1, x_2, \dots, x_n spočítáme jejich harmonický průměr jako

$$\bar{x}_H = \frac{n}{\frac{1}{x_1} + \frac{1}{x_2} + \dots + \frac{1}{x_n}} = \frac{n}{\sum_{i=1}^n \frac{1}{x_i}}$$

► MS Excel®

=HARMEAN($x_1 : x_n$)

- pro n nenulových hodnot x_1, x_2, \dots, x_n tvořících soubor m čísel takových, že je mezi nimi číslo x_1 právě m_1 -krát, číslo x_2 právě m_2 -krát, \dots , číslo x_n právě m_n -krát a je $m_1 + m_2 + \dots + m_n = m$, spočítáme jejich harmonický průměr jako

$$\bar{x}_H = \frac{m}{\frac{m_1}{x_1} + \frac{m_2}{x_2} + \dots + \frac{m_n}{x_n}} = \frac{m}{\sum_{i=1}^n \frac{m_i}{x_i}}$$

Příklad

- Lod' pluje z říčního přístavu k ústí řeky rychlostí $v_1 > 0$, poté se vrací stejnou trasou zpět do přístavu rychlostí $v_2 > 0$. Určete průměrnou rychlost lodi na celkové trase z říčního přístavu k ústí řeky a zpět.

Příklad

- Totožná součástka se vyrábí na dvou automatech. Starší z nich vyrobí 1 kus každých 10 minut, nový každých 6 minut.
 - (i) Jak dlouho trvá v průměru výroba jedné součástky?
 - (ii) Jak dlouho trvá v průměru výroba jedné součástky, pracuje-li starší automat 5 hodin denně a nový 8 hodin denně?
 - (iii) Jaká je týdenní produkce součástek, pracují-li oba stroje na maximum, tj. 8 hodin denně, 7 dní v týdnu?

Příklad

- Investor se rozhodl pravidelně investovat do určité akcie každý měsíc fixní částku 10 000 Kč po dobu 3 měsíců. Cena jedné akcie byla první měsíc 100 Kč, druhý měsíc 125 Kč a třetí měsíc 80 Kč. Jaká byla průměrná pořizovací cena jedné akcie?

Vztah mezi aritmetickým, geometrickým a harmonickým průměrem

- pro n nezáporných čísel x_1, x_2, \dots, x_n spočítáme jejich aritmetický průměr \bar{x} , geometrický průměr \bar{x}_G a harmonický průměr \bar{x}_H
- pak platí

$$\bar{x}_H \leq \bar{x}_G \leq \bar{x}$$

a rovnost nastává tehdy a jen tehdy, pokud je $x_1 = x_2 = \cdots = x_n$

- vztahu $\bar{x}_G \leq \bar{x}$ se někdy též říká AG nerovnost („aritmeticko-geometrická“)

Medián


- medián je „prostřední“ prvek, zhruba polovina hodnot je větší než medián a zbylá polovina hodnot je menší než medián
- pro n čísel x_1, x_2, \dots, x_n zjistíme jejich medián tak, že
 - (i) čísla seřadíme vzestupně, tj. pro původní vektor hodnot $(x_1, x_2, \dots, x_n)^T$ získáme vektor hodnot $(x_{(1)}, x_{(2)}, \dots, x_{(n)})^T$, kde pro $\forall i \in \{1, 2, \dots, n\}$ je $x_{(i)}$ právě i -tá nejmenší hodnota ve vektoru $(x_1, x_2, \dots, x_n)^T$
 - (ii) medián \tilde{x} je prostřední hodnota (pro n liché), resp. aritmetický průměr z „prostředních“ dvou hodnot (pro n sudé)

► MS Excel®

=MEDIAN($x_1 : x_n$)


Příklad

- určíme medián z následujícího souboru tělesných výšek




Příklad

- určíme medián z následujícího souboru tělesných výšek
- $\tilde{x} = 171 \text{ [cm]}$




Příklad

- určíme medián z následujícího souboru tělesných výšek
- $\tilde{x} = 171 \text{ [cm]}$
- kolik navzájem různých mediánů může mít jeden soubor čísel?



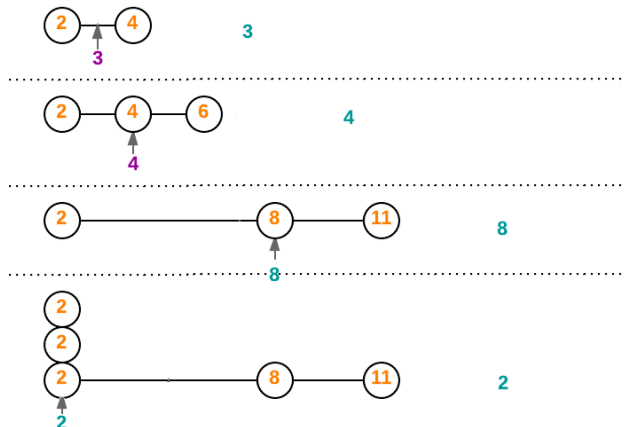
Příklad

- určíme medián z následujícího souboru tělesných výšek
- $\tilde{x} = 171 \text{ [cm]}$
- kolik navzájem různých mediánů může mít jeden soubor čísel?
- pouze jeden



Geometrická interpretace mediánu

- pokud na pravítku vyznačíme pozice čísel x_1, x_2, \dots, x_n , hodnota mediánu \tilde{x} má od všech vyznačených bodů nejmenší možný součet vzdáleností



p -tý kvantil

- nad souborem čísel x_1, x_2, \dots, x_n se p -tý kvantil značí \tilde{x}_p a je definován jako

$$\tilde{x}_p = \begin{cases} x_{(\lfloor k \rfloor + 1)}, & \text{pro } k = np \notin \mathbb{N} \\ \frac{1}{2} (x_{(k)} + x_{(k+1)}) , & \text{pro } k = np \in \mathbb{N}, \end{cases}$$

kde $x_{(k)}$ je k -té nejmenší číslo mezi čísly x_1, x_2, \dots, x_n , dále kde $0 \leq p \leq 1$ a kde $\lfloor x \rfloor$ značí dolní celou část čísla x , tedy nejvyšší celé číslo takové, že nepřevýší x ; tedy např. $\lfloor 4,3 \rfloor = 4$, $\lfloor 1 \rfloor = 1$ a $\lfloor -2,8 \rfloor = -3$

- pravděpodobnost, že hodnota v dané souboru nepřevýší hodnotu \tilde{x}_p , je rovna p , tedy

$$x \in (x_1, x_2, \dots, x_n)^T \implies P(x \leq \tilde{x}_p) = p$$

- zhruba $100p$ % hodnot v souboru $(x_1, x_2, \dots, x_n)^T$ je menších než nebo rovných hodnotě \tilde{x}_p

p -tý kvantil pro vybrané hodnoty $0 \leq p \leq 1$

p	p -tý kvantil	triviální název
0,25	$\tilde{x}_{0,25}$	první kvartil
0,50	$\tilde{x}_{0,50}$	medián
0,75	$\tilde{x}_{0,75}$	třetí kvartil

Modus

- modus je hodnota statistického znaku, který se v souboru čísel vyskytuje nejčastěji
 - pozor, modem není četnost takového prvku, tj. v souboru $\{10, 11, 11, 12\}$ je modem hodnota 11, nikoliv 2
- pro n hodnot x_1, x_2, \dots, x_n tvořících soubor m čísel takových, že je mezi nimi číslo x_1 právě m_1 -krát, číslo x_2 právě m_2 -krát, \dots , číslo x_n právě m_n -krát a je $m_1 + m_2 + \dots + m_n = m$, určíme jejich modus jako

$$\hat{x} = \arg \max_{i \in \{1, 2, \dots, n\}} \{m_i\}$$


- všimněme si, že takových hodnot \hat{x} ale může být více než jedna

► MS Excel®

=MODE($x_1 : x_n$)

Příklad


- určíme modus z následujícího souboru tělesných výšek





Příklad


- určíme modus z následujícího souboru tělesných výšek
- $\hat{x} = \{165; 176\}$ [cm]
- kolik navzájem různých modů může mít jeden soubor čísel?



Příklad

- určíme modus z následujícího souboru tělesných výšek
- $\hat{x} = \{165; 176\}$ [cm]
- kolik navzájem různých modů může mít jeden soubor čísel?
- alespoň jeden

18.4



Příklad

- určeme aritmetický průměr a medián u každého z obou následujícího souborů

$$x_1 = \{1, 2, 3, 4, 5\} \quad x_2 = \{1, 2, 3, 4, 90\}$$

Příklad

- určeme aritmetický průměr a medián u každého z obou následujícího souborů


$$x_1 = \{1, 2, 3, 4, 5\} \quad x_2 = \{1, 2, 3, 4, 90\}$$



$$\bar{x}_1 = \tilde{x}_1 = 3; \quad \bar{x}_2 = 20; \quad \tilde{x}_2 = 3$$




- která z měr polohy (průměr, medián) lépe vyhovuje „asymetrickým“ datům?

Journal of Management Education 36(7) 809–826




Příklad

- který z krabicových diagramů nedává smysl?



- 1 [1]


1. *Journal of the American Medical Association*, 1997; 278: 1019-1024.




Popis kvalitativního znaku

- např. krevní skupiny, grading tumoru, pohlaví, atd.
- číselně
 - absolutní, relativní četnosti
- graficky
 - koláčový diagram

- určíme absolutní a relativní četnost krevní skupiny A



- určíme absolutní a relativní četnost krevní skupiny A
- $n_A = 4$; $\pi_A = \frac{4}{12} = \frac{1}{3}$



- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡



Hindls, Richard, Markéta Arltová, Stanislava Hronová, Ivana Malá, Luboš Marek, Iva Pecáková a Řezanková Hana. *Statistika v ekonomii*. Praha: Professional Publishing, 2018. ISBN: 978-80-88260-09-7.



Marek, Luboš. *Statistika v příkladech*. Praha: Professional Publishing, 2015. ISBN: 978-80-7431-153-6.

Děkuji za pozornost!

lubomir.stepanek@vse.cz

lubomir.stepanek@lf1.cuni.cz

lubomir.stepanek@fbmi.cvut.cz